BIG DATA #2

AGENDA

Dia 1 - Visão Geral e Hadoop

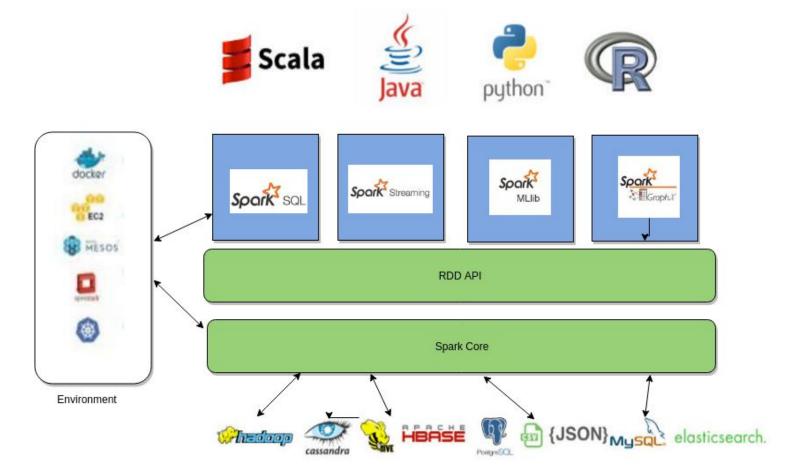
Dia 2 - Sparklyr, Parquet, MongoDB e outros

SPARK

Desenvolvido em 2009 no AMPLab da Universidade de Berkeley e disponibilizado em código aberto pela fundação Apache em 2010

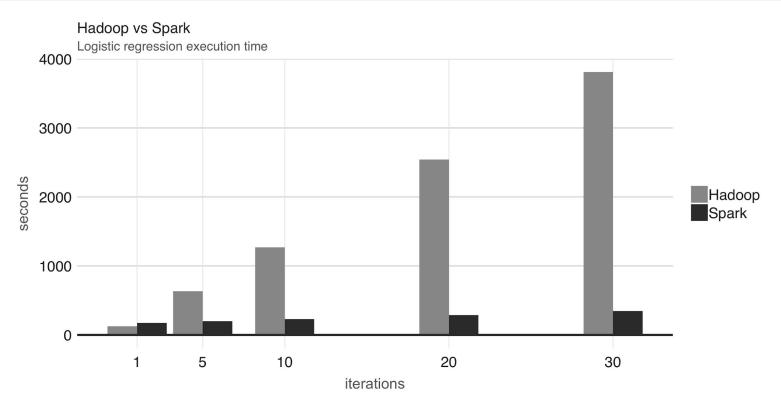
- Framework
- Processamento em memória
- Escrito em Scala





Source

SPARK



SPARK

	Hadoop Record	Spark Record	
Data Size	102.5 TB	100 TB	
Elapsed Time	72 mins	23 mins	
Nodes	2100	206	
Cores	50400	6592	
Disk	3150 GB/s	618 GB/s	
Network	10Gbps	10Gbps	
Sort rate	1.42 TB/min	4.27 TB/min	
Sort rate / node	0.67 GB/min	20.7 GB/min	

SPARKLYR

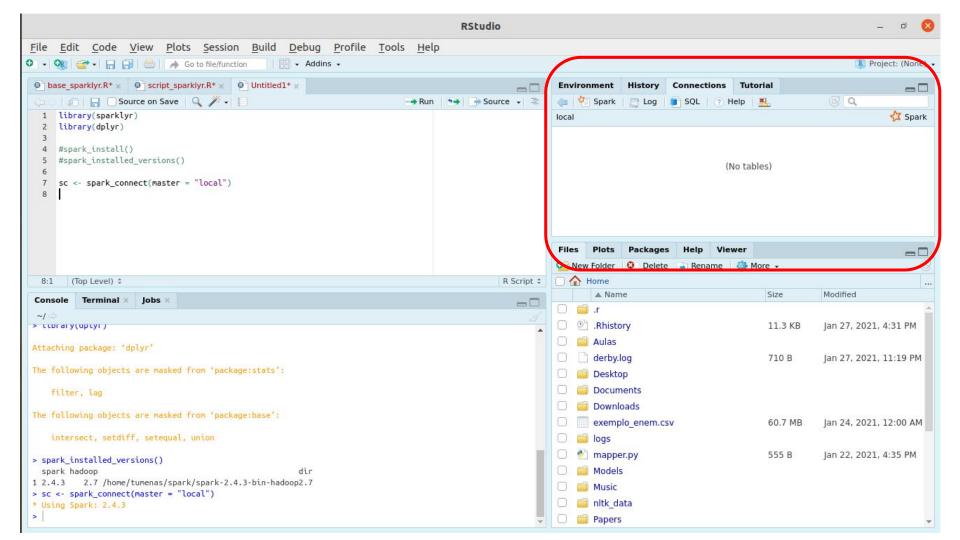
https://spark.rstudio.com/

- Connect to Spark from R. The sparklyr package provides a complete dplyr backend.
- Filter and aggregate Spark datasets then bring them into R for analysis and visualization.
- Use Spark's distributed machine learning library from R.
- Create extensions that call the full Spark API and provide interfaces to Spark packages.



SPARKLYR (INSTALAÇÃO)

```
system("java -version") (Necessário ter Java 8 instalado)
install.packages("sparklyr")
spark_install()
spark_installed_versions()
```





Spark Jobs (?)

User: tumenas Total Uptime: 12 s Scheduling Mode: FIFO Completed Jobs: 1

▶ Event Timeline

- Completed Jobs (1)

Job ld ▼	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
0	count at utils.scala:116 count at utils.scala:116	2021/01/27 23:19:50	0,7 s	2/2	2/2

spark_web(sc)

SPARKLYR

Inserir dados

```
cars <- copy_to(sc, mtcars)
cars
count(cars)</pre>
```

Gráfico com amostra

```
select(cars, hp, mpg) %>%
sample_n(100) %>%
collect() %>%
plot()
```

Modelos

```
model <- ml_linear_regression(cars, mpg ~ hp)
model
```

https://therinspark.com/

O'REILLY®

Mastering Spark with R

The Complete Guide to Large-Scale Analysis and Modeling



Javier Luraschi, Kevin Kuo & Edgar Ruiz Foreword by Matei Zaharia

PARQUET

Lançado em 2013 (desenvolvido pelo Twitter + Cloudera).

Projetado como armazenamento colunar eficiente (em comparação a arquivos CSV ou TSV)



PARQUET

Dataset	Size on Amazon S3	Query Run time	Data Scanned	Cost
Data stored as CSV files	1 TB	236 seconds	1.15 TB	\$5.75
Data stored in Apache Parquet format*	130 GB	6.78 seconds	2.51 GB	\$0.01
Savings / Speedup	87% less with Parquet	34x faster	99% less data scanned	99.7% savings

https://dzone.com/articles/how-to-be-a-hero-with-powerful-parquet-google-and

CONVERSÃO PARQUET (SPARKLYR)

CONVERSÃO PARQUET (SPARKLYR)



3,2 Gb 638 Mb

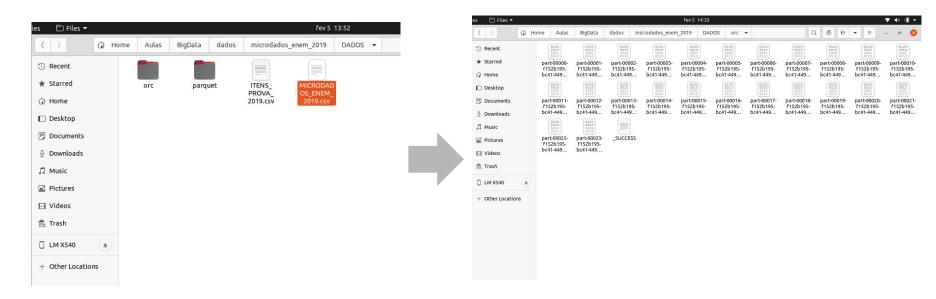
ORC

- -Lançado em 2013 (Hortonworks + Facebook)
- -Optimized Row Columnar
- -Transações ACID

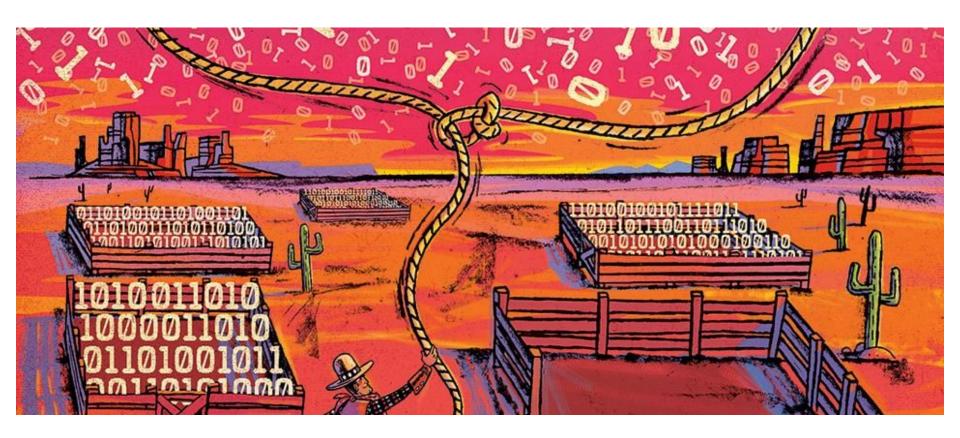


CONVERSÃO ORC (SPARKLYR)

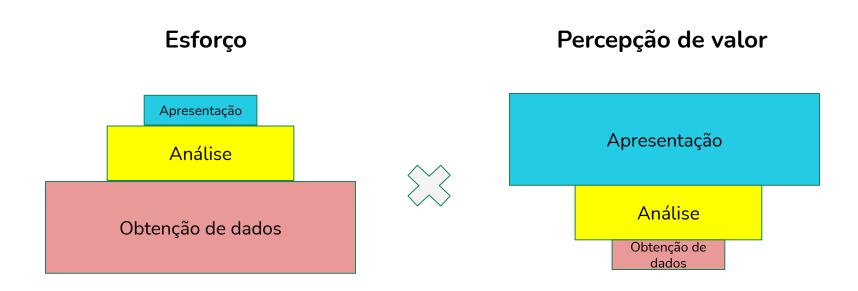
CONVERSÃO ORC (SPARKLYR)



3,2 Gb 693 Mb



PROCESSO DE ANÁLISE DA DADOS



REST

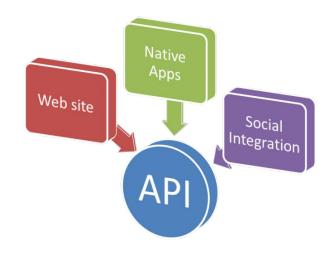
"Representational State Transfer (REST), em português Transferência de Estado Representacional, é um estilo de arquitetura que define um conjunto de restrições e propriedades baseados em <u>HTTP</u>. Web Services que obedecem ao estilo arquitetural REST, ou <u>web services</u> RESTful, fornecem interoperabilidade entre sistemas de computadores na <u>Internet</u>. Os web services compatíveis com REST permitem que os sistemas solicitantes acessem e manipulem representações textuais de recursos da Web usando um conjunto uniforme e predefinido de operações sem estado. Outros tipos de web services, como web services <u>SOAP</u>, expõem seus próprios conjuntos arbitrários de operações."

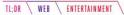
"Um conjunto de operações bem definidas que se aplicam a todos os recursos de informação: HTTP em si define um pequeno conjunto de operações, as mais importantes são POST, GET,..."

404

API

Application Programming Interface: conjunto de padrões e rotinas estabelecidos que permitem a interoperabilidade entre aplicações.





Iron Maiden makes millions of dollars by playing live for pirates (update)

By Rich McCormick | Dec 25, 2013, 9:59pm EST

SHARE



MOST READ

122



Xiaomi's translucent Mi 8 Explorer Edition has an in-display fingerprint sensor and 3D face unlock



iron-maiden-flickr

EXERCÍCIO API

QUAIS SÃO AS 10 MÚSICAS DO IRON MAIDEN MAIS TOCADAS NO BRASIL NO SPOTIFY?

SPOTIFY

```
install.packages('spotifyr')
#library(devtools)
#devtools::install_github('charlie86/spotifyr')
library(spotifyr)
iron maiden <- get artist audio features('iron maiden')
iron_maiden_TopTracks <- get_artist_top_tracks('6mdiAmATAx73kdxrNrnlao', market = "BR",
       authorization = get spotify access token(),
       include meta info = FALSE)
```



http://open-notify.org/

EXERCÍCIO API

```
library(httr)

astros = GET("http://api.open-notify.org/astros.json")

farol = GET("http://api.open-notify.org/iss-pass.json",

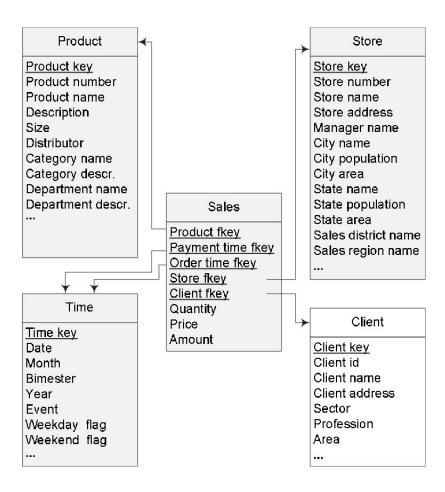
query = list(lat = -13.009565000112607, lon = -38.53302776815651))
```

JSON

"JSON (JavaScript Object Notation) é um formato de representação e intercâmbio de dados complexos e heterogêneos "

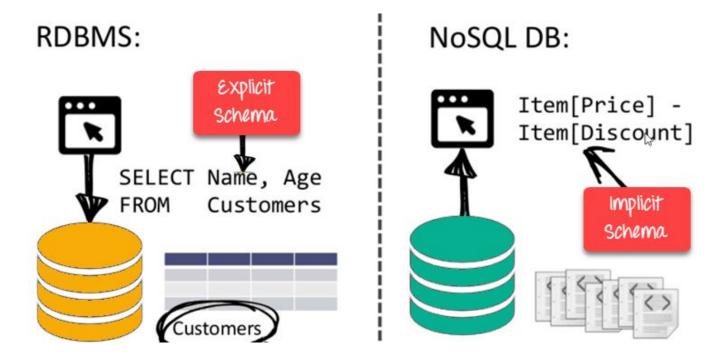
```
"id": "00000234567894",
"name": "Jane Doe",
"birthday": "04/18/1978",
"gender": "female",
"type": "user",
"work": [{
   "employer": {
      "id": "106119876543210",
      "name": "Doe Inc."
   "start date": "2007 - 08"
 },
  "start date": "2004",
  "end date": "2007"
} ]
```

IMHOF, Rudimar; FROZZA, Angelo Augusto; DOS SANTOS MELLO, Ronaldo. Um Survey sobre Extração de Esquemas de Documentos JSON. In: **Anais da XIII Escola Regional de Banco de Dados**. SBC, 2017.



MALINOWSKI, Elzbieta; ZIMÁNYI, Esteban. Conceptual Modeling for Data Warehouse and OLAP Applications. In: **Encyclopedia of Data Warehousing and Mining, Second Edition**. IGI Global, 2009. p. 293-300.

RDBMS x NoSQL



NoSQL (Not Only SQL)



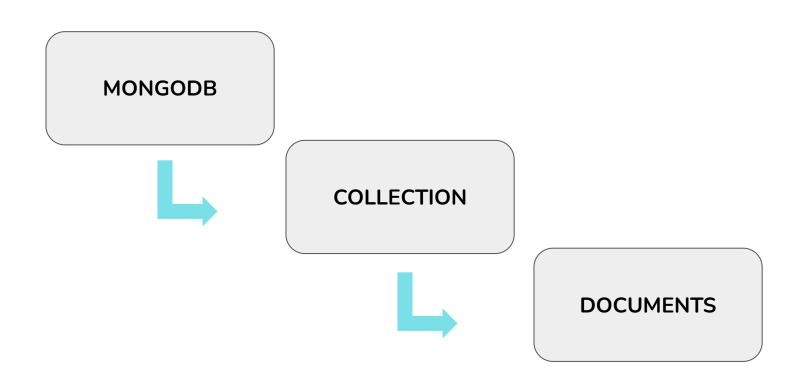
MONGODB

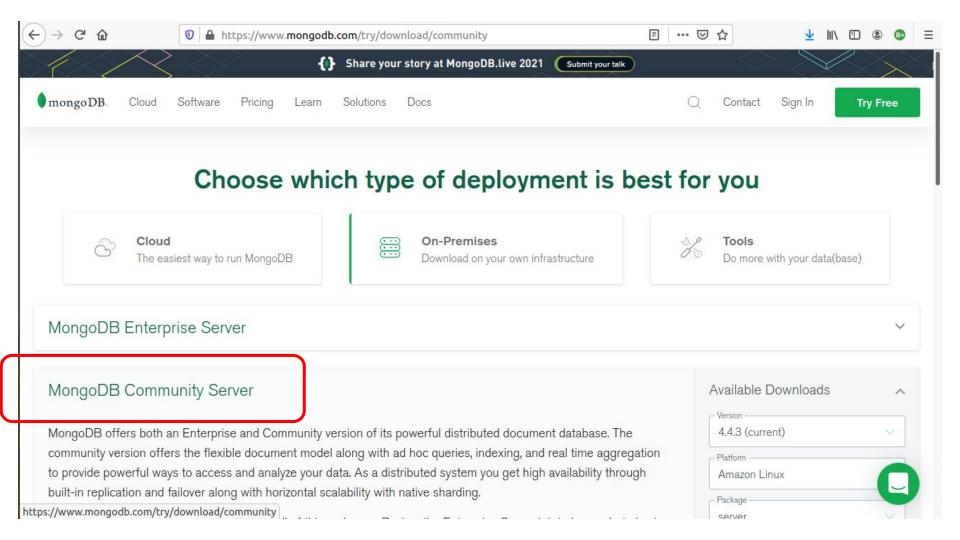
Lançado em 2009, é um banco de dados de código aberto, gratuito, de alta performance, sem schemas e orientado à documentos



https://www.mongodb.com/

MONGODB





MONGOLITE

```
install.packages("mongolite")
devtools::install_github("jeroen/mongolite")
library(mongolite)
m <- mongo(collection = "diamonds")
# Insert test data
data(diamonds, package="ggplot2")
m$insert(diamonds)
# Check records
m$count()
# Perform a query and retrieve data
out <- m$find('{"cut" : "Premium", "price" : { "$lt" : 1000 } }')
```

MONGOLITE TUTORIAL

https://jeroen.github.io/mongolite/